先聚类，再训练

基于数据指纹的联邦学习概念发现
——面向周期性概念漂移场景

2026 年 4 月

目录

1. 背景与动机
2. 理论基础
3. 方法：FedProTrack
4. 实验
5. 总结

问题设定：概念漂移下的联邦学习

- K 个客户端，T 轮通信，C 个隐含**概念**
- 每轮中，客户端 k 从概念 $c(k,t) \in [C]$ 的分布采样数据
- 概念会**周期性复现**：客户端访问概念 b 后可能回到概念 a
- 服务器无法看到原始数据——只能通过聚合信号间接推断

目标：推断隐含概念身份 → 分组客户端 → 按概念联邦聚合

Oracle（性能上界）：每轮已知真实 $c(k,t)$

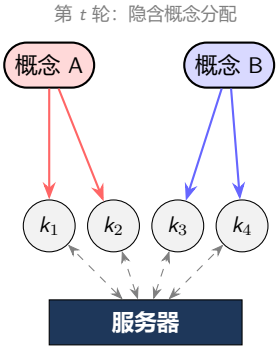

核心设计选择：何时聚类？

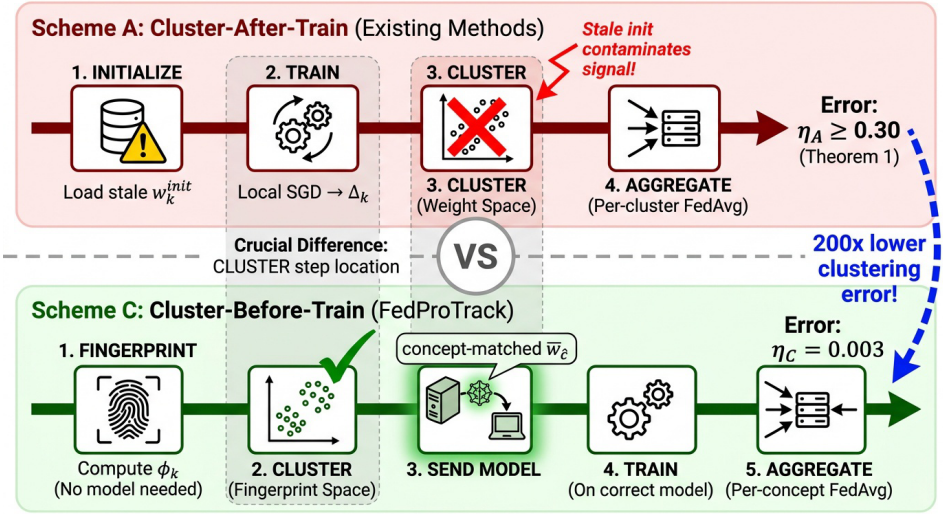

定理 1：$\eta_A \geq \eta_A^{(\text{clean})} + \kappa \cdot \mathbb{V}(w^{(\text{init})})$ $\Rightarrow$ 方案 A：$\eta \geq 0.30$ vs 方案 C：$\eta = 0.003$

概念级聚合何时有效?

The Bias-Variance Tradeoff

Risk formulas for Global vs. Concept-Level aggregation

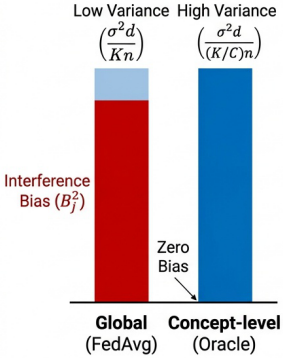

The Sharp Crossover

Analytical crossover condition ($\mathrm{SNR} > C - 1$) validated by synthetic experiments

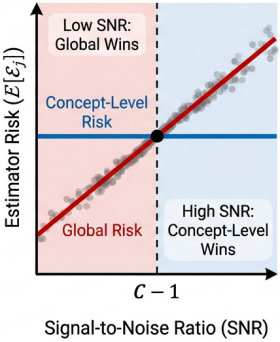

Implicit Shrinkage Mechanism

Conceptually: Imperfect clustering on the model weight space

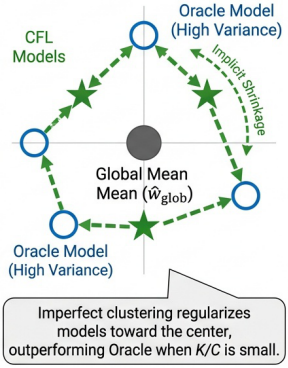

左：偏差-方差权衡　**中**：在 $\mathrm{SNR} = C-1$ 处的尖锐交叉点　**右**：不完美聚类 = 隐式收缩

现有方法：方案 A（先训练后聚类）

几乎所有聚类联邦学习方法都遵循同一协议：

步骤 1	步骤 2	步骤 3	步骤 4
加载上轮模型 $w_k^{(\mathrm{init})}$	本地训练	对 $\{\Delta_k\}$ 聚类	分组 FedAvg

典型方法：IFCA、CFL、FedEM、FedRC、FedGWC、基于梯度的划分...

隐含假设

权重更新 Δ_k 能忠实反映客户端的当前概念身份。

但在概念复现场景下，这一假设不成立。

陈旧初始化问题

当客户端从概念 a 切换到概念 b 时，它加载的是上次在 a 上训练的模型：

$$\Delta_k = \underbrace{-\alpha \nabla L_b(\bar{w}_b)}_{\text{真实概念-}b\text{ 信号}} + \underbrace{\alpha H_k\left(w_k^{(\text{init})} - \bar{w}_b^{(t-1)}\right)}_{\text{陈旧初始化污染}} + O(\|\cdot\|^2)$$

- 污染项与概念 b **完全无关**
- 其大小正比于 $\|w_k^{(\text{init})} - \bar{w}_b\|$——即" 初始化失配"
- 任何在 Δ_k 上做聚类的算法都会被**结构性误导**

$\Rightarrow$ **这不是算法问题——而是协议结构问题。**

定理：陈旧初始化放大效应

定理 (主定理——无条件成立)

在标准正则性条件下（L-光滑，μ-强凸）：

$$\boxed{\eta_A \;\geq\; \eta_A^{(\mathrm{clean})} \;+\; \kappa \cdot \mathbb{V}(w^{(\mathrm{init})})}$$

其中 $\mathbb{V}(w^{(\mathrm{init})}) > 0$ **只要概念存在复现。**

三个关键推论：

1. **无条件**：仅需标准假设，无需额外条件
2. $\mathbb{V}(w^{(\mathrm{init})}) > 0$ 在概念复现下是**结构性**的——**无法消除**
3. 方案 A 框架内的任何算法改进都无法缩小这一差距

从聚类误差到多余风险（推论 1）：

结合隐式收缩刻画，多余风险差距

$\geq (\eta_A - \eta_C) \cdot \frac{C}{C-1} \cdot \bar{B}^2 > 0$

实验证据：所有方案 A 方法均 $\eta \geq 0.30$

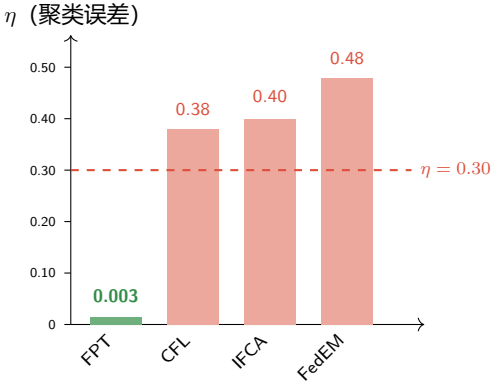

- 在 CIFAR-100 上，**所有**方案 A 方法：$\eta \geq 0.38$
- FPT 达到 $\eta = 0.003$——**低两个数量级**
- 该差距是结构性的，非算法差异

即使使用 Oracle 初始化（消除 $\mathbb{V}$）：
$\eta_A^{(\text{clean})} = 0.40$ vs $\eta_C = 0.002$

$\Rightarrow$ 指纹具有内在的 d/L 信噪比优势
（引理 2：$d = 128$，$L = 10 \Rightarrow 12.8\times$）

FedProTrack：总览

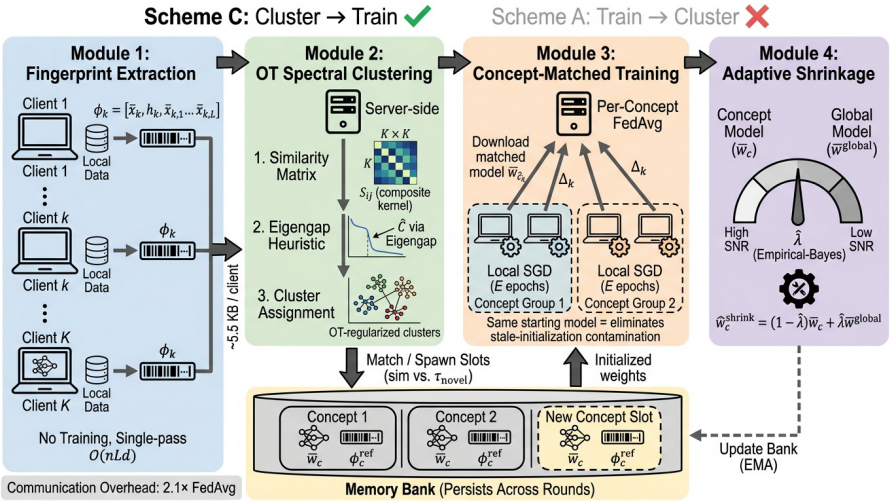

方案 C：指纹提取 → OT 谱聚类 → 概念匹配训练 → 自适应收缩（2.1× FedAvg 通信量）

模块 1：指纹提取

每个客户端**无需模型训练**即可计算数据指纹：

$$\phi_k = \Big[\underbrace{\bar{x}_k}_{\text{全局均值}},\ \underbrace{h_k}_{\text{标签分布}},\ \underbrace{\bar{x}_{k,1},\ \ldots,\ \bar{x}_{k,L}}_{\text{类条件均值}}\Big]$$

为什么这样设计？

- 类条件均值 = 概念身份的**充分统计量**
- 单次扫描 $O(nLd)$，无需梯度计算
- d=128，L=10 ⇒ 每客户端仅 **5.5 KB**

信噪比优势（引理 2）：

$$\frac{\mathrm{SNR}_{\mathrm{fp}}}{\mathrm{SNR}_{\mathrm{wt}}} = \frac{d}{L} = \frac{128}{10} = 12.8\times$$

指纹以一阶矩编码概念信号；权重则将其埋入二次形式（$X^\top X$）中。

模块 2：OT 谱聚类——步骤 1：相似度矩阵

给定 K 个指纹 $\{\phi_1, \ldots, \phi_K\}$，服务器计算：

$$S_{ij} = \underbrace{0.25 \cdot \mathrm{sim}_{\mathrm{feat}}(\phi_i, \phi_j)}_{\text{全局均值高斯核}} + \underbrace{0.30 \cdot \mathrm{sim}_{\mathrm{label}}(h_i, h_j)}_{\text{标签直方图余弦相似}} + \underbrace{0.45 \cdot \mathrm{sim}_{\mathrm{cc}}(\phi_i, \phi_j)}_{\text{类条件高斯核}}$$

- 权重在留出的合成数据上固定，**不在评估数据上调优**
- $\mathrm{sim}_{\mathrm{cc}}$ 权重最大：类条件结构携带最多概念信号
- **鲁棒性**：4 种权重配置下精度变化 ≤ 0.2pp

理论联系：对于共享协方差的高斯类分布，类条件均值的欧氏距离 $\approx$ **Wasserstein-2**：
$W_2^2(P_a, P_b) = \sum_c w_c \|\mu_a^{(c)} - \mu_b^{(c)}\|^2$

模块 2：OT 谱聚类——步骤 2：特征间隙

通过归一化拉普拉斯矩阵**自动确定概念数量**：

1. 构造 $L_{\text{sym}} = I - D^{-1/2} S D^{-1/2}$
2. 计算特征值 $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_K$
3. 找到最大间隙：

$$\hat{C} = \arg\max_{c \in [2, K/2]} (\lambda_{c+1} - \lambda_c)$$

直觉：C 个分离良好的簇 $\Rightarrow$ C 个特征值 ≈ 0，然后出现**跳跃**

结果：特征间隙在 $>95\%$ 的轮次中正确恢复 $\hat{C}=4$。固定 $\hat{C}=C$ 仅损失 0.6pp。

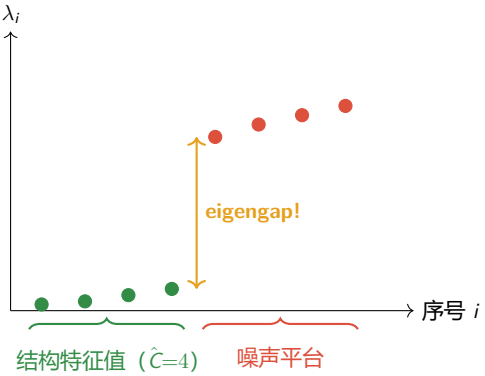

模块 2：OT 谱聚类——步骤 3：OT 正则化分配

标准谱聚类：取前 $\hat{C}$ 个特征向量 → 行归一化 → k-means。

问题：k-means 可能产生空/极小簇——1 个客户端的组没有聚合收益。

OT 正则化替代 k-means：

$$\min_{\pi} \sum_{i,c} \pi_{ic} \|v_i - \mu_c\|^2$$

$$\text{s.t.} \quad \sum_{c} \pi_{ic} = 1 \quad \forall i$$

$$\sum_{i} \pi_{ic} \geq \lfloor K/(2\hat{C}) \rfloor \quad \forall c \text{（最小簇大小）}$$

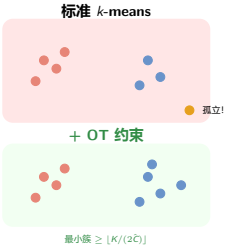

模块 3：记忆库与概念匹配

记忆库 $\mathcal{M} = \{(\bar{w}_c, \phi_c^{\text{ref}})\}$ 存储每个概念的模型和参考指纹。

匹配：将每个新簇质心与已存概念比较：

- $\text{sim} \geq \tau_{\text{novel}}$：重新识别 $\rightarrow$ 加载已存模型
- $\text{sim} < \tau_{\text{novel}}$：新概念 $\rightarrow$ 创建新槽位

τ_{novel}：成对相似度分布的第 95 百分位

关键：休眠概念被召回而非重新学习。

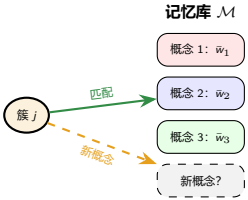

模块 4：概念匹配训练与自适应收缩

概念匹配训练

客户端 k（属于概念 $\hat{c}_k$）从记忆库接收 $\bar{w}_{\hat{c}_k}^{(t-1)}$：

$$\Delta_k^{(t)} = w_k^{(t)} - \bar{w}_{\hat{c}_k}^{(t-1)}$$

$$\bar{w}_c^{(t)} = \bar{w}_c^{(t-1)} + \frac{1}{|\mathcal{C}_c|} \sum_{k \in \mathcal{C}_c} \Delta_k^{(t)}$$

同一概念组 $\mathcal{C}_c$ 的客户端从**同一**模型出发 $\Rightarrow$ **纯概念信号**，无陈旧初始化。

自适应收缩

$$\hat{w}_c^{\text{shrink}} = (1-\hat{\lambda})\bar{w}_c^{(t)} + \hat{\lambda}\,\bar{w}^{(t)}$$

$$\hat{\lambda} = \frac{\hat{\sigma}^2/((K/\hat{C})n)}{\hat{\sigma}^2/((K/\hat{C})n) + \hat{\sigma}_B^2}$$

- **高 SNR**：$\hat{\lambda} \to 0$，完全概念特定
- **低 SNR**：$\hat{\lambda} \to 1$，退化为 FedAvg

安全网：即使聚类有噪声或 SNR 较低，FPT 也不会显著恶化。

实验设置

4 个数据集：

- **CIFAR-100**（旗舰，5 种配置）
- **Fashion-MNIST**
- **fMoW**（自然时序漂移）
- **CIFAR-10**（阴性对照）

$K=20$，$T=100$，$C=4$，复现周期 $\rho=25$

冻结 ResNet-18 特征，PCA 降至 $d=128$

线性分类器（1290 参数）

统一预算：5 epochs，lr=0.01

来自 7 个家族的 26 个基线：

- 先训练后聚类：IFCA、CFL、FedEM、FedRC
- 延迟聚类：HCFL、FedGWC
- 漂移感知：FedDrift、Flash、FedCCFA
- 个性化：FedProx、APFL、Ditto、pFedMe
- 核心：FedAvg、Oracle、LocalOnly
- 其他：FLUX、SCAFFOLD、...

各基线使用**发表默认值**；在留出配置上网格搜索。

主要结果

方法	精度 (↑) CIFAR-100	F-MNIST	fMoW	CIFAR-10	聚类误差 η (C-100)
Oracle	.673	.974	.599	.940	.000
FedAvg	.631	.912	.506	.917	—
CFL	.623	.922	.507	.916	.38
IFCA	.599	.821	.502	.713	.40
FedEM	.523	.866	.416	.857	.48
APFL	.640	.924	.515	.905	—
Flash	.635	.920	.508	.917	—
FPT（本方法）	**.670**	**.973**	**.584**	.907	**.003**
Oracle 差距 (pp)	4.7	6.1	9.3	2.3	
缩小比例	**93%**	**98%**	**84%**	-43%	

FPT 缩小 84–98% 的 Oracle 差距（差距 > 4pp） | 所有方案 A：$\eta \geq 0.38$，低于 FedAvg |
CIFAR-10（阴性对照）：FPT 优雅退化

消融实验：每个模块都不可或缺

变体	精度	η
FPT（完整版）	$.716 \pm .031$	$.003 \pm .001$
– 概念发现	$.684 \pm .028$	—
– 自适应收缩	$.704 \pm .033$	$.003 \pm .001$
– 指纹 $\to$ 权重 （方案 A）	$.688 \pm .035$	$.39 \pm .04$
– 特征间隙（固定 $\hat{C}=C$）	$.710 \pm .030$	$.004 \pm .001$

关键行：指纹 $\to$ 权重空间聚类

η：$0.003 \to 0.39$，精度：$0.716 \to 0.688$

$\Rightarrow$ 孤立了**协议排序效应**

- – 概念发现：-3.2pp
- – 收缩：-1.2pp
- – 特征间隙：-0.6pp（可靠）

补充分析

K 扩展性

- K=4 时 CFL 匹配 Oracle（隐式收缩在 K/C 较小时有益）
- K=20 时 CFL 落后 3.7pp
- FPT：在**所有** K 值下 $\eta \leq 0.01$
- 验证了推论 1（隐式收缩）

通信开销

- FPT：每轮 $2.1\times$ FedAvg
- 指纹上传：5.5 KB
- 服务器端聚类：< 1ms（K=20）
- 相比最优 $1\times$ 基线提升 $+3.0$–6.9pp

边界条件

- **无复现**（ρ=15, T=30）：FPT $\approx$ FedAvg，差距 -0.1pp ($\hat{\lambda} \to 1$，收缩主导)
- **端到端 CNN**（EMNIST）：FPT 达到 89–90%（中等水平）特征漂移破坏了指纹可比性

权重敏感性

- 核权重 $(\alpha_1, \alpha_2, \alpha_3)$：测试了 4 种配置
- 精度变化 ≤ 0.2pp
- η_C 不变

局限性

1. **冻结骨干假设**——FPT 依赖稳定的特征表示；端到端训练会破坏跨轮指纹可比性 (EMNIST：中等水平)
2. **高斯线性模型的理论**——定理 1 在 L-光滑、强凸损失下证明；非凸扩展是未来工作
3. **规模**——实验使用 $K \leq 40$；谱聚类复杂度 $O(K^3)$，扩展到 $K > 1000$ 需要 Nyström 近似
4. **隐私**——指纹是聚合统计量（非原始数据），但正式的差分隐私分析超出本文范围

核心结论

1. **“何时聚类”是关键设计维度**
   方案 A 受到**无条件**的陈旧初始化放大效应——这是协议层面的，而非算法层面的
2. **数据指纹 $>$ 权重更新（用于概念发现）**
   d/L 信噪比优势：$\eta_C = 0.003$ vs $\eta_A \geq 0.38$（相差两个数量级）
3. **FedProTrack：完整的方案 C 实现**
   OT 谱聚类 + 概念记忆库 + 自适应收缩 = 在 4 个数据集、26 个基线上**缩小 84–98% 的 Oracle 差距**（$2.1\times$ FedAvg 通信量）
4. **自适应收缩 = 安全网**
   当概念结构较弱时，优雅退化为 FedAvg